



Data Science

Program Studi Informatika

Sesi 4 – Statistika Dasar & Analisis Data

Syahid Abdullah, S.Si, M.Kom



Outline



Statistika Deskriptif

Mean, median, modus, varians, std, kuartil, persentil, IQR



Distribusi & Univariat

Normal, skewed, bimodal, skewness, kurtosis, histogram, boxplot



Analisis Bivariat

Scatter plot, korelasi Pearson & Spearman, heatmap korelasi



Hands-on Coding

Eksplorasi dataset Iris: 6 langkah praktikum Python lengkap



Statistika Deskriptif

Mean · Median · Modus · Varians · Standar Deviasi · Kuartil · Persentil · IQR



Ukuran Penyebaran Data: Mean, Median & Modus

Mean (Rata-rata)

$$\mu = \frac{\sum x_i}{n}$$

```
df['col'].mean()  
np.mean(arr)
```

Median (Nilai Tengah)

nilai tengah data terurut

```
df['col'].median()  
np.median(arr)
```

Modus (Frekuensi Tertinggi)

argmax frekuensi

```
df['col'].mode()[0]  
stats.mode(arr)
```

Perbandingan & Kapan Digunakan

Ukuran	Keunggulan	Kelemahan	Gunakan saat...
Mean	Memanfaatkan semua nilai data	Sensitif terhadap outlier	Data numerik, distribusi simetris
Median	Tahan outlier (robust)	Mengabaikan nilai ekstrem	Data miring atau ada outlier
Modus	Berlaku untuk data kategorik	Bisa lebih dari satu modus	Data kategorik atau frekuensi

💡 Jika mean $\neq$ median $\rightarrow$ distribusi miring (skewed) atau terdapat outlier. Selalu periksa keduanya!



Ukuran Pemusatan Data: Varians & Standar Deviasi

Varians (σ^2)

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{n}$$

Rata-rata kuadrat selisih dari mean.

```
df['col'].var()  
np.var(arr)
```

Standar Deviasi (σ)

$$\sigma = \sqrt{\frac{\sum (x_i - \mu)^2}{n}}$$

Akar varians — satuan sama dengan data asli.

```
df['col'].std()  
np.std(arr)
```

Eksplorasi Lengkap dengan Python

```
import pandas as pd  
import numpy as np  
from scipy import stats  
import seaborn as sns  
  
df = sns.load_dataset('iris')  
  
# Statistik lengkap satu kolom  
col = df['sepal_length']  
  
print(f"Count      : {col.count()}")  
print(f"Mean       : {col.mean():.3f}")  
print(f"Median      : {col.median():.3f}")  
print(f"Modus       : {col.mode()[0]:.3f}")  
print(f"Std Dev     : {col.std():.3f}")  
print(f"Varians     : {col.var():.3f}")  
print(f"Min-Max    : {col.min()} - {col.max()}")  
print(f"Range      : {col.max()-col.min():.3f}")  
print(f"Skewness   : {col.skew():.3f}")  
print(f"Kurtosis   : {col.kurt():.3f}")  
  
# Ringkasan semua kolom  
print(df.describe().round(3))
```



Ukuran Pemusatan Data: Kuartil, Persentil & IQR

Q1 — Persentil ke-25

25% data berada di bawah nilai ini

```
df['col'].quantile(0.25)
```

Q2 — Median (P50)

50% data berada di bawah nilai ini

```
df['col'].quantile(0.50)
```

Q3 — Persentil ke-75

75% data berada di bawah nilai ini

```
df['col'].quantile(0.75)
```

IQR = Q3 - Q1

Rentang antar-kuartil, robust terhadap outlier

```
IQR = Q3 - Q1
```

Aturan IQR Fence: Batas bawah = $Q1 - 1.5 \times IQR$ | Batas atas = $Q3 + 1.5 \times IQR$

Implementasi Python

```
import pandas as pd
import numpy as np
import seaborn as sns

df = sns.load_dataset('iris')
col = df['sepal_length']

Q1 = col.quantile(0.25)
Q2 = col.quantile(0.50)
Q3 = col.quantile(0.75)
IQR = Q3 - Q1

print(f"Q1 = {Q1:.2f}")
print(f"Q2 = {Q2:.2f} (Median)")
print(f"Q3 = {Q3:.2f}")
print(f"IQR = {IQR:.2f}")

# Batas outlier IQR Fence
lower = Q1 - 1.5 * IQR
upper = Q3 + 1.5 * IQR
outliers = col[(col < lower) | (col > upper)]
print(f"Outlier: {len(outliers)} baris")

# Banyak persentil sekaligus
percs = [10, 25, 50, 75, 90, 95]
vals = np.percentile(col, percs)
for p, v in zip(percs, vals):
    print(f"P{p:2d} = {v:.2f}")
```




Distribusi Data

Normal · Right-Skewed · Left-Skewed · Bimodal · Skewness · Kurtosis



Jenis Distribusi Data

Normal (Simetris)



Skewness ≈ 0


Mean = Median = Modus

Contoh:

Tinggi badan, skor IQ

```
df['col'].skew()
```

Right-Skewed (+)



Skewness > 0


Mean $>$ Median $>$ Modus

Contoh:

Pendapatan, harga rumah

```
df['col'].skew()
```

Left-Skewed (-)



Skewness < 0


Mean $<$ Median $<$ Modus

Contoh:

Usia pensiun, nilai ujian mudah

```
df['col'].skew()
```

Bimodal



Dua puncak

Kemungkinan dua sub-populasi

Contoh:

Tinggi badan pria & wanita

```
df['col'].skew()
```




Skewness & Kurtosis: Mengukur Bentuk Distribusi

SKEWNESS — Ukuran Asimetri

< -1

Miring kiri kuat

-1 hingga -0.5

Miring kiri moderat

-0.5 hingga 0.5

Simetris / normal

0.5 hingga 1

Miring kanan moderat

> 1

Miring kanan kuat

```
skew = df['col'].skew()
print(f"Skewness: {skew:.3f}")
```

KURTOSIS — Ukuran Ketebalan Ekor

Leptokurtic ($K > 3$)

Ekor tebal, puncak runcing
Banyak nilai ekstrem / outlier

Mesokurtic ($K = 3$)

Distribusi normal standar
Sebaran data seimbang

Platykurtic ($K < 3$)

Ekor tipis, puncak datar
Data sangat merata terdistribusi

```
kurt = df['col'].kurt()
# Pandas: excess kurtosis
# Normal → kurt() ≈ 0 (bukan 3)
```



Analisis Univariat

Analisis Satu Variabel: Histogram · KDE · Boxplot · Violin Plot



Histogram & KDE (Kernel Density Estimation)

Histogram

Membagi data menjadi bin (interval) dan menghitung frekuensi. Menampilkan bentuk distribusi data secara langsung.

KDE (Kernel Density Estimation)

Versi halus histogram — estimasi densitas probabilitas tanpa bins diskret. Lebih smooth dan informatif untuk perbandingan.

Parameter Kunci

- bins: jumlah interval histogram
- kde=True: tambahkan kurva KDE
- bw_adjust: kehalusan kurva KDE (default=1)

💡 Gunakan kde=True untuk membandingkan distribusi antar grup — KDE lebih mudah dibaca daripada histogram yang saling bertumpuk.

Kode Python

```
import matplotlib.pyplot as plt
import seaborn as sns

df = sns.load_dataset('iris')

fig, axes = plt.subplots(1, 2, figsize=(12,5))


# Histogram dasar
axes[0].hist(df['sepal_length'], bins=20,
             color='#028090', edgecolor='white',
             alpha=0.85)
axes[0].set_title('Histogram Sepal Length')
axes[0].set_xlabel('Sepal Length (cm)')
axes[0].set_ylabel('Frekuensi')

# Histogram + KDE per spesies
sns.histplot(data=df, x='sepal_length',
             hue='species', kde=True,
             palette='Set2', alpha=0.6,
             ax=axes[1])
axes[1].set_title('Distribusi per Spesies')

plt.tight_layout()
plt.savefig('histogram_iris.png', dpi=150)
plt.show()
```



Boxplot & Violin Plot



Boxplot vs Violin Plot

Boxplot: ringkas, ideal untuk perbandingan banyak grup, mudah dibaca semua audiens.

Violin Plot: menampilkan bentuk distribusi penuh + boxplot, lebih informatif, cocok untuk eksplorasi.

Kode Python

```
import seaborn as sns
import matplotlib.pyplot as plt

df = sns.load_dataset('iris')

fig, axes = plt.subplots(1, 2, figsize=(12,5))

# Boxplot per spesies
sns.boxplot(data=df,
            x='species', y='petal_length',
            palette='Set2', ax=axes[0])
axes[0].set_title('Boxplot Petal Length')
axes[0].set_xlabel('Species')
axes[0].set_ylabel('Petal Length (cm)')

# Violin plot (distribusi + box)
sns.violinplot(data=df,
              x='species', y='sepal_length',
              palette='Set2', inner='box',
              ax=axes[1])
axes[1].set_title('Violin Plot Sepal Length')

plt.tight_layout()
plt.show()
```



Analisis Bivariat

Analisis Dua Variable: Scatter Plot · Korelasi Pearson · Korelasi Spearman · Heatmap



Scatter Plot: Hubungan Dua Variabel Numerik

Pola yang Dapat Terdeteksi



Korelasi Positif

X naik → Y naik. Tren ke kanan atas.



Korelasi Negatif

X naik → Y turun. Tren ke kanan bawah.



Tidak Berkorelasi

Titik tersebar acak, tanpa pola jelas.



Hubungan Non-Linear

Ada pola tapi bukan garis lurus.

Kode Python

```
import seaborn as sns
import matplotlib.pyplot as plt

df = sns.load_dataset('iris')

fig, axes = plt.subplots(1, 2, figsize=(12,5))

# Scatter dasar
axes[0].scatter(
    df['sepal_length'],
    df['petal_length'],
    alpha=0.7, color='#028090', s=50)
axes[0].set_xlabel('Sepal Length (cm)')
axes[0].set_ylabel('Petal Length (cm)')
axes[0].set_title('Scatter Plot Dasar')

# Scatter per spesies + garis regresi
sns.scatterplot(data=df, x='sepal_length',
                y='petal_length', hue='species',
                palette='Set2', ax=axes[1])
sns.regplot(data=df, x='sepal_length',
            y='petal_length', scatter=False,
            color='gray', ax=axes[1])
axes[1].set_title('Scatter + Regression Line')

plt.tight_layout()
plt.show()
```



Korelasi Pearson (r)

Rumus:

$$r = \frac{\sum[(x_i - \bar{x})(y_i - \bar{y})]}{n \cdot \sigma_x \cdot \sigma_y}$$

Rentang: $-1 \leq r \leq +1$

Gunakan: Data numerik, distribusi normal, hubungan linear

```
df.corr(method='pearson')  
r, p = stats.pearsonr(x, y)
```

Interpretasi
Nilai Korelasi

Nilai (+)	Interpretasi	Nilai (-)	Interpretasi
0.9 – 1.0	Sangat Kuat (+)	-0.9 – 1.0	Sangat Kuat (+)
0.7 – 0.9	Kuat (+)	-0.7 – 0.9	Kuat (+)
0.5 – 0.7	Sedang (+)	-0.5 – 0.7	Sedang (+)
0.3 – 0.5	Lemah (+)	-0.3 – 0.5	Lemah (+)
0.0 – 0.3	Sangat Lemah	-0.0 – 0.3	Sangat Lemah



Korelasi Spearman (ρ)

Rumus:

$$\rho = 1 - \frac{6\sum d^2}{n(n^2 - 1)}$$

Rentang: $-1 \leq \rho \leq +1$

Gunakan: Data ordinal atau tidak normal, atau ada outlier

```
df.corr(method='spearman')  
rho, p = stats.spearmanr(x, y)
```

```
from scipy import stats  
  
x = df['sepal_length']  
y = df['petal_length']  
  
r, p = stats.pearsonr(x, y)  
rho, p2 = stats.spearmanr(x, y)  
  
print(f"Pearson r = {r:.3f} (p={p:.4f})")  
print(f"Spearman ρ = {rho:.3f} (p={p2:.4f})")
```




Heatmap: Visualisasi Matriks Korelasi

Simulasi Heatmap Iris Dataset



Merah = korelasi positif kuat | Biru = korelasi negatif kuat
Putih/terang = lemah atau tidak berkorelasi

Kode Python

```
import seaborn as sns
import matplotlib.pyplot as plt

df = sns.load_dataset('iris')

# Matriks korelasi (tanpa kolom kategorik)
corr = df.drop('species', axis=1)
      .corr(method='pearson')
print(corr.round(2))

# Heatmap
fig, ax = plt.subplots(figsize=(8, 6))
sns.heatmap(corr,
            annot=True,      # tampilkan nilai korelasi
            fmt='.2f',       # format 2 desimal
            cmap='RdBu_r',   # merah=positif, biru=negatif
            vmin=-1, vmax=1,
            square=True,
            linewidths=0.5,
            linecolor='white',
            ax=ax)
ax.set_title('Heatmap Korelasi - Iris Dataset',
            fontsize=14, pad=12)
plt.tight_layout()
plt.show()
```



Aktivitas Hands-on

Lakukan aktivitas sesuai Panduan yang tertera pada Modul Pembelajaran 4



Terima Kasih